

[SWCON253] Machine Learning – Lec.12

# Overfitting & Regularization

---

Fall 2025

김 휘 용

[hykim.v@khu.ac.kr](mailto:hykim.v@khu.ac.kr)



# Contents

1. Overfitting & Underfitting
2. Regularization by Weight Penalty

## References

- 기계학습 by 오일석 (한빛아카데미, <http://cv.jbnu.ac.kr/index.php?mid=ml>)
- *Intro to Machine Learning* by Dmitry Kobak @Tubingen Univ.  
(<https://www.youtube.com/watch?v=brkS6rAKTl4&list=PL05umP7R6ij35ShKLDqccJSDntugY4FQT&index=3>)

# 1. Overfitting & Underfitting

- ✓ Underfitting
- ✓ Overfitting
- ✓ Causes of Overfitting


# Underfitting

## ◆ Underfitting(과소적합)과 훈련 오차

- 모델의 ‘**용량이 너무 작아**’(훈련집합에 대해서 조차) 오차가 클 수밖에 없는 현상
- 예) 아래 그림의 선형(1차 다항식) 또는 2차 다항식 모델을 사용한 경우

## ◆ Underfitting 방지

- 비선형 모델 등과 같이 **용량이 더 큰 모델을 사용한다**
- 예) 아래 그림의 3차, 4차, 12차 다항식 모델의 경우




# Overfitting

## ◆ Overfitting(과잉적합)과 예측(시험) 오차

- 앞의 예에서, 12차 다항식 곡선을 채택한다면 훈련집합에 대해 거의 완벽하게 근사화함
- 하지만 '새로운' 데이터를 예측한다면 큰 문제 발생(빨간 점)
- 이유는 '용량이 너무 크기' 때문에 학습 과정에서 잡음까지 수용 → 과잉적합 현상

## ◆ Overfitting 방지: 다양한 방법이 있음

- 적절한 용량의 모델을 선택하는 모델 선택 작업을 수행
- 앞의 예에서는 4차 다항식을 적절한 모델로 볼 수 있음




- 1차: 훈련집합과 테스트집합 모두 낮은 성능
- 12차: 훈련집합에 높은 성능, 테스트집합에는 낮은 성능 → 낮은 일반화 능력 (과잉적합)
- 4차: 훈련집합에 12차보다 낮은 성능, 테스트집합에는 높은 성능 → 높은 일반화 능력

# Causes of Overfitting – 1. Data

## ◆ Insufficient # of Training Examples

- the training set may be too sparse or cannot represent the full variety of the data



$N$ : # of training examples

- 해결책: 충분히 많은 Training Data 사용


★ Cf.) 데이터 증대(Data Augmentation) 기법 등을 통해 기존 Training Data 증대 가능

# Causes of Overfitting – 2. Model

## ◆ Too Large # of Parameters (Model Capacity)

- the model is relatively too flexible for the dataset
- the resulting parameters tend to have large values

M: the highest order of the polynomial  
( $M+1$ : the # of parameters)



	$M = 0$	$M = 1$	$M = 3$	$M = 9$
$w_0^*$	0.19			
$w_1^*$		-1.27		
$w_2^*$			-25.43	
$w_3^*$			17.37	
$w_4^*$				-231639.30
$w_5^*$				640042.26
$w_6^*$				-1061800.52
$w_7^*$				1042400.18
$w_8^*$				-557682.99
$w_9^*$				125201.43

→ magnitudes of parameters are very large!

# Causes of Overfitting – 2. Model (cont'd)

## ◆ 해결책 1: 검증집합(Validation Set)을 이용한 모델선택(Model Selection)

- 훈련집합과 테스트집합과 다른 별도의 **검증집합**을 준비한다.
- **모델집합**에 속한 각각의 모델에 대해 **훈련집합**으로 학습시킨다. (훈련 성능)
  - ★ 앞의 예에서는 서로 다른 차수의 다항식의 집합(서로 다른 용량)이 모델집합인 셈
- **검증집합**에 대해 최고의 성능을 보인 모델을 선택한다. (검증 성능) → **Overfitting 방지**

→ Lecture 13 ‘Model Evaluation’에서 배울 예정

## ◆ 해결책 2: 규제(Regularization)

- 용량이 충분히 큰 모델 + 다양한 **규제(Regularization)** 기법을 적용
  - ★ 예시: **Weight Penalty**, Drop-out...
  - ★ Overfitting을 방지하기 위한 기술을 통칭하여 ‘규제’라고 부르기도 함
  - ★ **Regularization Parameter**들은 **Validation Set**을 이용하여 결정 가능 (model selection)

→ 다음 슬라이드부터 배울 예정

## 2. Regularization by Weight Penalty

- ✓ Regularization
- ✓ Regularization by Weight Penalty
- ✓ L1 Norm vs. L2 Norm
- ✓ Selecting Lambda
- ✓ Do not penalize the bias!
- ✓ Example: Linear Regression

# Regularization (규제)

## ◆ 규제는 오래 전부터 수학과 통계학에서 연구해온 주제

- 모델 용량에 비해 데이터가 부족한 경우의 불량 문제를 ill-posed problem 푸는 데 사용

$$\underbrace{J_{\text{regularized}}(\Theta)}_{\substack{\text{규제를 적용한 목적함수}}} = \underbrace{J(\Theta)}_{\substack{\text{목적함수}}} + \lambda \underbrace{R(\Theta)}_{\substack{\text{규제 항}}}$$

- 현대 기계 학습도 규제를 널리 사용함

## ◆ 『Deep Learning』 책의 규제 정의

- "... any modification we make to a learning algorithm that is intended to *reduce its generalization error ...*"  
(일반화 오류를 줄이려는 의도를 가지고 학습 알고리즘을 수정하는 방법 모두)

## ◆ 명시적 규제와 암시적 규제

- **명시적 규제**: 가중치 감소나 드롭아웃처럼 목적함수나 신경망 구조를 직접 수정하는 방식
- **암시적 규제**: 조기 멈춤, 데이터 증대, 잡음 추가, 앙상블처럼 간접적으로 영향을 미치는 방식

# Regularization by Weight Penalty (가중치 감쇠)

## ◆ Regularized Cost Function

$$\underbrace{J_{\text{regularized}}(\Theta; \mathbb{X}, \mathbb{Y})}_{\text{규제를 적용한 목적함수}} = \underbrace{J(\Theta; \mathbb{X}, \mathbb{Y})}_{\text{목적함수}} + \lambda \underbrace{R(\Theta)}_{\text{규제 항}}$$

- 규제항은 훈련집합과 무관하며, 데이터 생성 과정에 내재한 사전 지식에 해당
- ◆ 규제항  $R(\Theta)$ 로 무엇을 사용할 것인가? → 가중치 감쇠 (가중치 벌칙)
  - 큰 가중치( $\Theta$ )에 벌칙을 가해 작은 가중치를 유지. 주로  $L_2$  놈이나  $L_1$  놈을 사용
    - ★  $L_2$  norm 사용:  $R(\Theta) = \|\Theta\|_2^2$
    - ★  $L_1$  norm 사용:  $R(\Theta) = \|\Theta\|_1$
    - ★ 최종해를 원점 가까이 당기는 효과 (즉 가중치를 작게 유지함)
  - 가중치 감쇠는 모델의 구조적 용량을 충분히 크게 하고 모델의 ‘수치적 용량’을 제한하는 규제 기법임

# Regularization – L2 Norm

## ◆ Regularized Cost & Gradient

$$J_{regularized}(\Theta; \mathbb{X}, \mathbb{Y}) = \underbrace{J(\Theta; \mathbb{X}, \mathbb{Y})}_{\text{목적함수}} + \lambda \underbrace{\|\Theta\|_2^2}_{\text{규제 항}}$$

$$\nabla J_{regularized}(\Theta; \mathbb{X}, \mathbb{Y}) = \nabla J(\Theta; \mathbb{X}, \mathbb{Y}) + \underline{2\lambda\Theta}$$


## ◆ Parameter Update

$$\Theta = \Theta - \rho \nabla J_{regularized}(\Theta; \mathbb{X}, \mathbb{Y})$$

$$= \Theta - \rho (\nabla J(\Theta; \mathbb{X}, \mathbb{Y}) + 2\lambda\Theta)$$

$$= \boxed{(1 - 2\rho\lambda)\Theta} - \rho \nabla J(\Theta; \mathbb{X}, \mathbb{Y})$$

- L<sub>2</sub> 규제는  $\Theta$ 를  $2\rho\lambda$ 의 비율로 줄인 후 업데이트 하는 셈  
★ 즉, 가중치 감소 정도가 현재 가중치 크기에 비례함



# Regularization – L1 Norm

## ◆ Regularized Cost & Gradient

$$\underbrace{J_{regularized}(\Theta; \mathbb{X}, \mathbb{Y})}_{\text{규제를 적용한 목적함수}} = \underbrace{J(\Theta; \mathbb{X}, \mathbb{Y})}_{\text{목적함수}} + \lambda \underbrace{\|\Theta\|_1}_{\text{규제 항}}$$


$$\nabla J_{regularized}(\Theta; \mathbb{X}, \mathbb{Y}) = \nabla J(\Theta; \mathbb{X}, \mathbb{Y}) + \lambda \underline{\text{sign}(\Theta)}$$

sign( $\Theta$ ) :  $\Theta$ 의 부호 벡터  
 $(1, -1)$


## ◆ Parameter Update

$$\begin{aligned}\Theta &= \Theta - \rho \nabla J_{regularized}(\Theta; \mathbb{X}, \mathbb{Y}) \\ &= \Theta - \rho (\nabla J(\Theta; \mathbb{X}, \mathbb{Y}) + \lambda \text{sign}(\Theta)) \\ &= \Theta - \rho \nabla J(\Theta; \mathbb{X}, \mathbb{Y}) \boxed{- \rho \lambda \text{sign}(\Theta)}\end{aligned}$$

- L1 규제는  $\Theta$ 를  $\rho\lambda$ (고정값)만큼 줄인 후 업데이트 하는 셈
- L1 규제의 희소성(Sparse) 효과: 0이 되는 가중치가 많이 발생
- ★ 선형 회귀에 적용하면 특징 선택 효과







(a)  $\text{sign}(\Theta) = (1,1)^T$ 인 경우



(b)  $\text{sign}(\Theta) = (-1,1)^T$ 인 경우

# Regularization – L1 norm vs. L2 norm


- ◆ Ridge (L2) vs. Lasso (L1) Regression (Linear Regression with L2/L1-Norms)



# Regularization – Selecting Lambda

- ◆ Test Error가 가장 작게 되는  $\lambda$ 가 최적

- 그러나 학습시에는 test set에 접근할 수 없으므로, validation set을 이용하여 최적의  $\lambda$ 를 선택함



# Regularization – Do Not Penalize Bias!

---

## ◆ For Centered Dataset (when both x and y have zero mean)

- No problem even if we have zero bias (i.e.,  $\beta_0 = 0$ ).

$$\mathcal{L} = \frac{1}{n} \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2 + \lambda \|\boldsymbol{\beta}\|^2$$

## ◆ For Non-centered Dataset (the general case)

- Penalizing bias often leads to bad performance.
- Thus we need to **exclude the bias ( $\beta_0$ ) from the regularization term**:

$$\mathcal{L} = \frac{1}{n} \sum_{i=1}^n \left( y_i - \beta_0 - \sum_{j=1}^p \beta_j X_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2.$$

# Regularization – Example: Linear Regression

## ■ 선형 회귀에 적용

- 선형 회귀는 훈련집합  $\mathbb{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ ,  $\mathbb{Y} = \{y_1, y_2, \dots, y_n\}$ 이 주어지면, 식 (5.24)를 풀어  $\mathbf{w} = (w_1, w_2, \dots, w_d)^T$ 를 구하는 문제. 이때  $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{id})^T$

$$w_1 x_{i1} + w_2 x_{i2} + \dots + w_d x_{id} = \mathbf{x}_i^T \mathbf{w} = y_i, \quad i = 1, 2, \dots, n \quad (5.24)$$

- 식 (5.24)를 행렬식으로 바꿔 쓰면,

$$\mathbf{X}\mathbf{w} = \mathbf{y} \quad (5.25)$$

$$\nabla_{\underline{x}} \underline{x}^T \underline{x} = 2 \underline{x}$$

- 가중치 감쇠를 적용한 목적함수

$$J_{regularized}(\mathbf{w}) = \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \lambda \|\mathbf{w}\|_2^2 = \frac{1}{2} (\mathbf{X}\mathbf{w} - \mathbf{y})^T (\mathbf{X}\mathbf{w} - \mathbf{y}) + \lambda \|\mathbf{w}\|_2^2 \quad (5.27)$$

$$\nabla_{\underline{x}} (\underline{x}^T \underline{x}) = 2 \underline{x}$$

$$= 2 \underline{x}^T (\mathbf{X}\mathbf{w} - \mathbf{y})$$

# Regularization – Example: Linear Regression (cont'd)

- 식 (5.27)을 미분하여 0으로 놓으면,

$$\frac{\partial J_{regularized}}{\partial \mathbf{w}} = \mathbf{X}^T \mathbf{X} \mathbf{w} - \mathbf{X}^T \mathbf{y} + 2\lambda \mathbf{w} = \mathbf{0} \Rightarrow (\mathbf{X}^T \mathbf{X} + 2\lambda \mathbf{I}) \mathbf{w} = \mathbf{X}^T \mathbf{y} \quad (5.28)$$

- 식 (5.28)을 정리하면,

$$\hat{\mathbf{w}} = (\mathbf{X}^T \mathbf{X} + 2\lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y} \quad (5.29) \rightarrow \text{Normal Eq. for Ridge Regression}$$

- 공분산 행렬  $\mathbf{X}^T \mathbf{X}$ 의 대각 요소가  $2\lambda$ 만큼씩 증가  $\rightarrow$  역행렬을 곱하므로 가중치를 축소하여 원점으로 당기는 효과 ([그림 5-21])

- 예측 단계에서는.

$$\hat{\mathbf{y}} = \mathbf{x}^T \hat{\mathbf{w}} \quad (5.30)$$

# Regularization – Example: Linear Regression (cont'd)

예제 5-1

리지 회귀

훈련집합  $\mathbb{X} = \{\mathbf{x}_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \mathbf{x}_2 = \begin{pmatrix} 2 \\ 3 \end{pmatrix}, \mathbf{x}_3 = \begin{pmatrix} 3 \\ 3 \end{pmatrix}\}$ ,  $\mathbb{Y} = \{y_1 = 3.0, y_2 = 7.0, y_3 = 8.8\}$ 이 주어졌다고 가정하자. 특징 벡터가 2차원이므로  $d=2$ 이고 샘플이 3개이므로  $n=3$ 이다. 훈련집합으로 설계행렬  $\mathbf{X}$ 와 레이블 행렬  $\mathbf{y}$ 를 다음과 같이 쓸 수 있다.

$$\mathbf{X} = \begin{pmatrix} 1 & 1 \\ 2 & 3 \\ 3 & 3 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 3.0 \\ 7.0 \\ 8.8 \end{pmatrix}$$

이 값들을 식 (5.29)에 대입하여 다음과 같이  $\hat{\mathbf{w}}$ 을 구할 수 있다. 이때  $\lambda = 0.25$ 라 가정하자.

$$\hat{\mathbf{w}} = \left( \begin{pmatrix} 1 & 2 & 3 \\ 1 & 3 & 3 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 2 & 3 \\ 3 & 3 \end{pmatrix} + \begin{pmatrix} 0.5 & 0 \\ 0 & 0.5 \end{pmatrix} \right)^{-1} \begin{pmatrix} 1 & 2 & 3 \\ 1 & 3 & 3 \end{pmatrix} \begin{pmatrix} 3.0 \\ 7.0 \\ 8.8 \end{pmatrix} = \begin{pmatrix} 1.4916 \\ 1.3607 \end{pmatrix}$$

따라서 하이퍼 평면은  $y = 1.4916x_1 + 1.3607x_2$ 이다. 새로운 샘플로  $\mathbf{x} = (5 \quad 4)^T$ 가 입력되면 식 (5.30)을 이용하여 12.9009를 예측한다.

# Q & A

본 강의 영상(자료)는 경희대학교 수업목적으로 제작·제공된 것으로 수업목적 외 용도로 사용할 수 없으며, 무단으로 복제, 배포, 전송 또는 판매하는 행위를 금합니다. 이를 위반 시 민·형사상 법적 책임은 행위자 본인에게 있습니다.