



[SWCON253] Machine Learning – Lec.15b

Support Vector Machine

Fall 2025

김휘용

hykim.v@khu.ac.kr



경희대학교

KYUNG HEE UNIVERSITY

Contents

1. Introduction
2. Linear SVM with Hard Margin
3. Linear SVM with Soft Margin
4. Nonlinear SVM (Kernel SVM)
5. SVM Training & Inference

References

- 기계 학습 by 오일석, 패턴 인식 by 오일석

3. Linear SVM with Soft Margin

- ✓ Hard vs. Soft Margin
- ✓ Linear SVM with Soft Margin
- ✓ Illustrative Example


Hard vs. Soft Margin

◆ 앞의 Linear SVM은 **Hard Margin**을 사용

- Hard Margin 내에는 샘플이 존재하지 않는다.
- Hard Margin을 사용하면 선형분리가 불가능한 상황에서는 해를 구할 수 없다.

◆ **Soft Margin & Slack Variable**

- Soft Margin이란 분할 때 안에도 샘플을 허용하는 것을 말한다.
- 각 샘플 (\mathbf{x}_i, y_i) 은 분할 때와의 위치 관계에 따라 다음 표의 세 가지 case 중 하나에 속하며, **슬랙 변수(Slack Variable)** ξ 를 도입하여 세 case를 하나로 표현할 수 있다.



Case	분류 결과	샘플 위치	그림 표시	$y_i(\mathbf{w}^T \mathbf{x}_i + b)$	슬랙 변수
1	옳게 분류	분할 때 바깥	● ○	$1 \leq y_i(\mathbf{w}^T \mathbf{x}_i + b)$	$\xi_i = 0$
2	옳게 분류	분할 때 안쪽	●	$0 \leq y_i(\mathbf{w}^T \mathbf{x}_i + b) < 1$	$0 < \xi_i \leq 1$
3	틀리게 분류	결정 경계 넘음	● ○	$y_i(\mathbf{w}^T \mathbf{x}_i + b) < 0$	$1 < \xi_i$



$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i$$


Linear SVM with Soft Margin – Formulation

◆ Problem Definition

여백을 될 수 있는 한 크게 하면서(목적 1), $0 < \xi$ 인 (즉, 경우 2와 경우 3에 속하는) 샘플의 수를 될 수 있는 한 적게 하는(목적 2) 결정 초평면의 방향 \mathbf{w} 를 찾아라.

$$\text{Min. } J(\mathbf{w}, \xi) = \underbrace{\frac{1}{2} \|\mathbf{w}\|_2^2}_{\text{}} + C \underbrace{\sum_{i=1}^n \xi_i}_{\text{}} \quad (C \text{는 hyper parameter})$$

$$\text{s.t. } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, i = 1, 2, \dots, n$$
$$0 \leq \xi_i, i = 1, 2, \dots, n$$



Linear SVM with Soft Margin – *Lagrange Method*

◆ Lagrangian

$$\mathcal{L}(\mathbf{w}, b, \xi, \alpha, \beta) = \left(\frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^n \xi_i \right) - \left(\sum_{i=1}^n \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1 + \xi_i) + \sum_{i=1}^n \beta_i \xi_i \right)$$

◆ KKT Condition → 결국 α_i, β_i 를 구하는 문제

$$\frac{\partial L}{\partial \mathbf{w}} = \mathbf{0} \quad \Rightarrow \quad \mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i$$

$$0 \leq \alpha_i, i = 1, 2, \dots, n$$

$$\frac{\partial L}{\partial b} = 0 \quad \Rightarrow \quad \sum_{i=1}^n \alpha_i y_i = 0$$

$$0 \leq \beta_i, i = 1, 2, \dots, n$$

$$\frac{\partial L}{\partial \xi_i} = 0 \quad \Rightarrow \quad C = \alpha_i + \beta_i, i = 1, 2, \dots, n$$

$$\alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1 + \xi_i) = 0, i = 1, 2, \dots, n$$

$$\beta_i \xi_i = 0, i = 1, 2, \dots, n$$

Linear SVM with Soft Margin – *Dual Problem*

◆ Wolfe Dual Problem

$$\text{Max.} \quad \tilde{L}(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$$

$$\text{s.t.} \quad \sum_{i=1}^n \alpha_i y_i = 0$$

$$0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, n$$

Linear SVM with Soft Margin – Example

◆ 선형분리가 불가능한 경우, Wolfe Dual Problem의 해를 구해 보자.

● 훈련 집합: $\mathbf{x}_1 = \begin{pmatrix} 2 \\ 3 \end{pmatrix}$, $\mathbf{x}_2 = \begin{pmatrix} 4 \\ 1 \end{pmatrix}$, $\mathbf{x}_3 = \begin{pmatrix} 5 \\ 1 \end{pmatrix}$, $y_1 = 1$, $y_2 = -1$, $y_3 = 1$

● Wolfe Dual Problem:

$$\text{Maximize: } \tilde{\mathcal{L}}(\boldsymbol{\alpha}) = (\alpha_1 + \alpha_2 + \alpha_3) - \frac{1}{2}(13\alpha_1^2 + 17\alpha_2^2 + 26\alpha_3^2 - 22\alpha_1\alpha_2 + 26\alpha_1\alpha_3 - 42\alpha_2\alpha_3)$$

$$\text{Subject to: } \alpha_1 - \alpha_2 + \alpha_3 = 0 \\ 0 \leq \alpha_1 \leq C, 0 \leq \alpha_2 \leq C, 0 \leq \alpha_3 \leq C$$


● 풀이:

★ Class별로 Support Vector가 하나 이상 있어야 하므로,
다음의 세 가지 경우만 가능하다.

(1) $\alpha_1 = 0$, $\alpha_2 \neq 0$, $\alpha_3 \neq 0$

(2) $\alpha_1 \neq 0$, $\alpha_2 \neq 0$, $\alpha_3 = 0$

(3) $\alpha_1 \neq 0$, $\alpha_2 \neq 0$, $\alpha_3 \neq 0$



Linear SVM with Soft Margin – Illustrative Example (cont'd)

(1) $\alpha_1 = 0, \alpha_2 \neq 0, \alpha_3 \neq 0$

$$\alpha_1 - \alpha_2 + \alpha_3 = 0 \text{ 으로부터 } \alpha_2 = \alpha_3$$

$$\tilde{\mathcal{L}}(\alpha) = 2\alpha_2 - \frac{1}{2}\alpha_2^2 = -\frac{1}{2}((\alpha_2 - 2)^2 - 4)$$

$$\Rightarrow \alpha_1 = 0, \alpha_2 = 2, \alpha_3 = 2$$

$$\mathbf{w} = (2, 0)^T, b = -9$$

$$d(\mathbf{x}) = 2x_1 - 9$$

$$d(\mathbf{x}_1) = -5, d(\mathbf{x}_2) = -1, d(\mathbf{x}_3) = 1$$

(2) $\alpha_1 \neq 0, \alpha_2 \neq 0, \alpha_3 = 0$

$$\alpha_1 - \alpha_2 + \alpha_3 = 0 \text{ 으로부터 } \alpha_1 = \alpha_2$$

$$\tilde{\mathcal{L}}(\alpha) = 2\alpha_1 - 4\alpha_1^2 = -4\left(\left(\alpha_1 - \frac{1}{4}\right)^2 - \frac{1}{16}\right)$$

$$\Rightarrow \alpha_1 = \frac{1}{4}, \alpha_2 = \frac{1}{4}, \alpha_3 = 0$$

$$\mathbf{w} = \left(-\frac{1}{2}, \frac{1}{2}\right)^T, b = \frac{1}{2}$$

$$d(\mathbf{x}) = -\frac{1}{2}x_1 + \frac{1}{2}x_2 + \frac{1}{2}$$

$$d(\mathbf{x}_1) = 1, d(\mathbf{x}_2) = -1, d(\mathbf{x}_3) = -\frac{3}{2}$$

(3) $\alpha_1 \neq 0, \alpha_2 \neq 0, \alpha_3 \neq 0$

$$\alpha_1 - \alpha_2 + \alpha_3 = 0 \text{ 으로부터 } \alpha_1 = \alpha_2 - \alpha_3$$


$$\frac{\partial \tilde{\mathcal{L}}(\alpha)}{\partial \alpha_2} = 0 \text{ 과 } \frac{\partial \tilde{\mathcal{L}}(\alpha)}{\partial \alpha_3} = 0 \text{ 을 풀면}$$

$$\Rightarrow \alpha_1 = \frac{3}{2}, \alpha_2 = \frac{13}{2}, \alpha_3 = 5$$

$$\mathbf{w} = (2, 3)^T, b = -12$$

$$d(\mathbf{x}) = 2x_1 + 3x_2 - 12$$

$$d(\mathbf{x}_1) = 1, d(\mathbf{x}_2) = -1, d(\mathbf{x}_3) = 1$$



Linear SVM with Soft Margin – Illustrative Example (cont'd)

◆ SVM은 (1)~(3) 중 어느 결정 직선을 선택하게 될까? → C 에 따라 다름

$$\begin{aligned}
 (1) \quad & \alpha_1 = 0, \alpha_2 = 2, \alpha_3 = 2 \Rightarrow \tilde{L}(\alpha) = 2 & d(\mathbf{x}_1) = -5, d(\mathbf{x}_2) = -1, d(\mathbf{x}_3) = 1 & \Rightarrow \frac{2}{\|\mathbf{w}\|_2} = 1 \\
 (2) \quad & \alpha_1 = \frac{1}{4}, \alpha_2 = \frac{1}{4}, \alpha_3 = 0 \Rightarrow \tilde{L}(\alpha) = \frac{1}{4} & d(\mathbf{x}_1) = 1, d(\mathbf{x}_2) = -1, d(\mathbf{x}_3) = -\frac{3}{2} & \Rightarrow \frac{1}{4} = 2\sqrt{2} \\
 (3) \quad & \alpha_1 = \frac{3}{2}, \alpha_2 = \frac{13}{2}, \alpha_3 = 5 \Rightarrow \tilde{L}(\alpha) = \frac{13}{2} & d(\mathbf{x}_1) = 1, d(\mathbf{x}_2) = -1, d(\mathbf{x}_3) = 1 & \Rightarrow \frac{2}{\sqrt{13}}
 \end{aligned}$$


● C 에 따른 유효성:

- ★ $C < 2$: 결정 직선 (2)만 유효 $0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, n$
- ★ $2 \leq C < 6.5$: 결정 직선 (1)과 (2)가 유효
- ★ $6.5 \leq C$: 결정 직선 (1)~(3)이 모두 유효
- ★ [참고] 여러 결정 직선이 유효한 경우에는, $\tilde{L}(\alpha)$ 가 큰 걸 선택함

● C 의 크기와 여백

$$J(\mathbf{w}, \xi) = \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^n \xi_i \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i$$

- ★ C 를 작게 하면 여백의 비중이 커진다. (여백 최대화)
- ★ C 를 크게 하면 ξ_i 의 비중이 커진다. (분할 때 안쪽 샘플 수 최소화)



Case	분류 결과	샘플 위치	슬랙 변수
1	옳게 분류	분할 때 바깥	$\xi = 0$
2	옳게 분류	분할 때 안쪽	$0 < \xi \leq 1$
3	틀리게 분류	결정 경계 넘음	$1 < \xi$

Q & A

본 강의 영상(자료)는 경희대학교 수업목적으로 제작·게시된 것이므로 수업목적 외 용도로 사용할 수 없으며, 무단으로 복제, 배포, 전송 또는 판매하는 행위를 금합니다. 이를 위반 시 민·형사상 법적 책임은 행위자 본인에게 있습니다.